

Entrega Final – Desafio XPE (Pipeline Postgres → Kafka → S3 → Spark)

Informações:

Repositorio: <https://github.com/fdelfino93/desafioxpe>

Bucket AWS: `ferdelfino-xpe` (regiao `us-east-2`)

Arquivos de evidencias (prints): `docs/img`

Visao geral

Pipeline ponta-a-ponta:

- Fonte: PostgreSQL (tabelas `public.dadostesouroipca` e `public.dadostesouopre`).
- Streaming: Kafka (Confluent Platform) com topics `postgres-dadostesouroipca` e `postgres-dadostesouopre`.
- Ingestao Data Lake: Kafka Connect S3 Sink (Avro converter + Schema Registry) gravando camada Bronze em S3.
- Processamento: Spark (master local[*] via notebook) lendo Bronze e gravando Silver (Parquet) e Gold (Parquet agregacoes).

Camadas:

- Bronze: `s3a://ferdelfino-xpe/bronze/ipca/` e `s3a://ferdelfino-xpe/bronze/pre/` (JSON).
- Silver: `s3a://ferdelfino-xpe/processed-data/ipca/silver/` e `.../pre/silver/` (Parquet).
- Gold: `s3a://ferdelfino-xpe/analytics/ipca/gold/` e `.../pre/gold/` (Parquet).

Para eu subir o ambiente (Docker)

```
```pwsh
cd "D:\Documents\Projeto\Prova\postgres"
docker-compose up -d

cd "D:\Documents\Projeto\Prova"
docker-compose up -d
docker ps --format "table {{.Names}}\t{{.Status}}\t{{.Ports}}"
...`
```

Esperado: broker, zookeeper, schema-registry, connect, postgres em estado Up.

## # Criar tópicos Kafka

```
```pwsh
docker exec broker kafka-topics --create --bootstrap-server localhost:9092 --partitions 1
--replication-factor 1 --topic postgres-dadostesouroipca
docker exec broker kafka-topics --create --bootstrap-server localhost:9092 --partitions 1
--replication-factor 1 --topic postgres-dadostesouopre
...`
```

Registrar conectores

Source (Postgres → Kafka):

```
```pwsh
cd "D:\Documents\Projeto\Prova\connectors\source"
curl -X POST -H "Content-Type: application/json" --data
@connect_jdbc_postgres_ipca.config http://localhost:8083/connectors
curl -X POST -H "Content-Type: application/json" --data @connect_jdbc_postgres_pre.config
http://localhost:8083/connectors
...`
```

Sink (Kafka → S3 Bronze) – ja configurados para bucket `ferdelfino-xpe`, regiao `us-east-2`, Avro + Schema Registry:

Evidencias (prints)

Conectores Kafka Connect RUNNING

Out[7]:

|  |         |                            | Taxa Compra Manhã | Taxa Venda Manhã | PU Compra Manhã | PU Venda Manhã | PU Base Manhã | Data_Vencimento | Data_Base |
|--|---------|----------------------------|-------------------|------------------|-----------------|----------------|---------------|-----------------|-----------|
|  | Tipo    | Título                     | Data Vencimento   | Data Base        |                 |                |               |                 |           |
|  | Tesouro | Prefixado                  | 01/01/2006        | 06/12/2005       | 18.26           | 18.29          | 988.09        | 988.07          | 987.41    |
|  | Tesouro | IPCA+ com Juros Semestrais | 15/08/2006        | 06/12/2005       | 12.88           | 12.90          | 1525.14       | 1524.96         | 1523.96   |
|  |         |                            | 15/05/2045        | 06/12/2005       | 9.07            | 9.17           | 1067.68       | 1056.28         | 1055.73   |
|  |         |                            | 15/08/2024        | 06/12/2005       | 9.00            | 9.08           | 1183.68       | 1175.01         | 1174.39   |
|  |         |                            | 15/05/2015        | 06/12/2005       | 8.98            | 9.04           | 1286.78       | 1281.80         | 1281.13   |
|  |         |                            | 15/05/2009        | 06/12/2005       | 11.20           | 11.24          | 1351.99       | 1350.48         | 1349.67   |
|  |         |                            | 15/05/2007        | 06/12/2005       | 11.90           | 11.92          | 1456.56       | 1456.20         | 1455.29   |
|  |         |                            | 15/08/2008        | 06/12/2005       | 11.43           | 11.47          | 1408.42       | 1407.18         | 1406.32   |
|  | Tesouro | IPCA+                      | 15/05/2015        | 06/12/2005       | 8.68            | 8.74           | 714.11        | 710.42          | 710.05    |
|  |         |                            | 15/08/2024        | 06/12/2005       | 8.82            | 8.90           | 323.79        | 319.39          | 319.22    |
|  | ...     |                            | ...               | ...              | ...             | ...            | ...           | ...             | ...       |
|  | Tesouro | Selic                      | 07/03/2015        | 02/08/2011       | 0.00            | 0.04           | 4799.08       | 4792.19         | 4789.95   |
|  |         |                            | 07/03/2014        | 02/08/2011       | 0.00            | 0.03           | 4799.08       | 4795.36         | 4793.11   |
|  |         |                            | 07/03/2017        | 02/08/2011       | 0.00            | 0.04           | 4799.08       | 4788.39         | 4786.14   |
|  |         |                            | 07/03/2013        | 02/08/2011       | 0.00            | 0.02           | 4799.08       | 4797.56         | 4795.32   |
|  |         |                            | 07/03/2012        | 02/08/2011       | 0.00            | 0.01           | 4799.08       | 4798.80         | 4796.55   |
|  | Tesouro | Prefixado                  | 01/01/2014        | 02/08/2011       | 12.82           | 12.88          | 747.49        | 746.53          | 746.17    |
|  |         |                            | 01/01/2013        | 02/08/2011       | 12.69           | 12.73          | 845.09        | 844.67          | 844.27    |
|  |         |                            | 01/01/2015        | 02/08/2011       | 12.85           | 12.91          | 661.63        | 660.43          | 660.11    |
|  |         |                            | 01/01/2012        | 02/08/2011       | 12.50           | 12.53          | 952.55        | 952.44          | 952.00    |
|  | Tesouro | IPCA+ com Juros Semestrais | 15/08/2024        | 02/08/2011       | 6.29            | 6.37           | 2067.28       | 2053.44         | 2052.81   |

164293 rows x 7 columns

S3/Gold IPCA (analytics)

Amazon S3 > Buckets > ferdelfino-xpe > analytics/ > ipca/ > gold/

gold/

Copiar URI do S3

ObjetosPropriedades

Objetos (2)

Os objetos são as entidades fundamentais armazenadas no Amazon S3. Você pode usar o [inventário do Amazon S3](#) para obter uma lista de todos os objetos em seu bucket. Para outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a eles. [Saiba mais](#)

Localizar objetos por prefixo

|  | Nome                                                                 | Tipo    | Última modificação          | Tamanho | Classe de armazenamento |
|--|----------------------------------------------------------------------|---------|-----------------------------|---------|-------------------------|
|  | _SUCCESS                                                             | -       | 23 Nov 2025 09:24:45 AM -03 |         | 0 B Padrão              |
|  | part-00000-4d21a762-7972-4a90-a0eb-1e78e9fa2221e-c000.snappy.parquet | parquet | 23 Nov 2025 09:24:42 AM -03 | 1.3 KB  | Padrão                  |

# S3/Gold PRE (analytics)

Amazon S3 > Buckets > ferdelfino-xpe > analytics/ > pre/ > gold/

gold/

Copiar URI do S3

Objetos

Propriedades

Objetos (2)

Os objetos são as entidades fundamentais armazenadas na Amazon S3. Você pode usar o [inventário do Amazon S3](#) para obter uma lista de todos os objetos em seu bucket. Para outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a eles. [Saiba mais](#)

Localizar objetos por prefixo

| <input type="checkbox"/> | Nome                                                                                | Tipo    | Última modificação          | Tamanho | Classe de armazenamento |
|--------------------------|-------------------------------------------------------------------------------------|---------|-----------------------------|---------|-------------------------|
| <input type="checkbox"/> | <a href="#">_SUCCESS</a>                                                            | -       | 23 Nov 2025 09:25:12 AM -03 |         | 0 B Padrão              |
| <input type="checkbox"/> | <a href="#">part-00000-788a7d6b-abf5-4e48-b65d-e5b1b04b7800-c000.snappy.parquet</a> | parquet | 23 Nov 2025 09:25:09 AM -03 | 1.3 KB  | Padrão                  |

# Consulta Postgres dadostesouroipca

DBeaver 25.2.5 - dadostesouroipca

Arquivo Editar Navegar Procurar Editor SQL Banco de dados Janela Ajuda

SQL Rollback Auto postgres public@postgres

Navegador de banco de dados

postgres public dadostesouroipca dadostesouroipre

Propriedades Dados Diagrama

Insira uma expressão SQL para filtrar os resultados (use Ctrl+Espaço)

|    | CompraManha | VendaManha | PUCCompraManha | PUVendaManha | PUBaseManha | Data_Vencimento         | Data_Base               | A2 Tipo | dt update               |
|----|-------------|------------|----------------|--------------|-------------|-------------------------|-------------------------|---------|-------------------------|
| 1  | 6,84        | 6,72       | 593,43         | 593,17       | 593,93      | 2024-08-15 00:00:00.000 | 2024-02-27 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.647 |
| 2  | 7,81        | 7,17       | 1.035,66       | 1.035,47     | 1.035,02    | 2015-05-15 00:00:00.000 | 2024-02-27 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.648 |
| 3  | 6,67        | 6,75       | 590,48         | 592,25       | 593         | 2024-08-15 00:00:00.000 | 2024-02-26 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.649 |
| 4  | 7,17        | 7,23       | 1.030,06       | 1.030,9      | 1.030,44    | 2015-05-15 00:00:00.000 | 2024-02-26 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.650 |
| 5  | 6,66        | 6,74       | 591,13         | 593,9        | 593,65      | 2024-08-15 00:00:00.000 | 2024-02-25 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.651 |
| 6  | 7,15        | 7,21       | 1.035,99       | 1.031,82     | 1.031,36    | 2015-05-15 00:00:00.000 | 2024-02-25 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.652 |
| 7  | 7,23        | 7,29       | 1.029,98       | 1.025,83     | 1.025,03    | 2015-05-15 00:00:00.000 | 2024-02-22 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.653 |
| 8  | 6,67        | 6,75       | 589,97         | 582,75       | 582,31      | 2024-08-15 00:00:00.000 | 2024-02-22 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.654 |
| 9  | 6,7         | 6,78       | 586,81         | 579,63       | 579,38      | 2024-08-15 00:00:00.000 | 2024-02-21 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.655 |
| 10 | 7,32        | 7,38       | 1.022,96       | 1.018,85     | 1.018,39    | 2015-05-15 00:00:00.000 | 2024-02-21 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.656 |
| 11 | 7,37        | 7,43       | 1.019,07       | 1.014,97     | 1.014,51    | 2015-05-15 00:00:00.000 | 2024-02-20 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.657 |
| 12 | 6,7         | 6,78       | 586,56         | 579,38       | 579,13      | 2024-08-15 00:00:00.000 | 2024-02-20 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.658 |
| 13 | 6,68        | 6,76       | 588,12         | 580,91       | 580,67      | 2024-08-15 00:00:00.000 | 2024-02-19 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.659 |
| 14 | 7,37        | 7,43       | 1.018,61       | 1.014,51     | 1.014,05    | 2015-05-15 00:00:00.000 | 2024-02-19 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.660 |
| 15 | 6,72        | 6,8        | 584,25         | 577,1        | 576,85      | 2024-08-15 00:00:00.000 | 2024-02-18 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.661 |
| 16 | 7,44        | 7,5        | 1.013,37       | 1.009,29     | 1.008,83    | 2015-05-15 00:00:00.000 | 2024-02-18 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.662 |
| 17 | 7           | 7,08       | 566,37         | 559,5        | 559,29      | 2024-08-15 00:00:00.000 | 2024-03-25 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.663 |
| 18 | 7,81        | 7,87       | 1.001,18       | 997,21       | 996,82      | 2015-05-15 00:00:00.000 | 2024-03-25 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.664 |
| 19 | 7,02        | 7,1        | 564,44         | 557,38       | 557,38      | 2024-08-15 00:00:00.000 | 2024-03-24 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.665 |
| 20 | 7,78        | 7,84       | 1.002,77       | 998,4        | 998,4       | 2015-05-15 00:00:00.000 | 2024-03-24 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.666 |
| 21 | 6,99        | 7,07       | 566,82         | 559,84       | 559,57      | 2024-08-15 00:00:00.000 | 2024-03-20 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.667 |
| 22 | 7,75        | 7,81       | 1.004,37       | 1.000,39     | 999,7       | 2015-05-15 00:00:00.000 | 2024-03-20 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.668 |
| 23 | 6,94        | 7,02       | 570,8          | 563,86       | 563,65      | 2024-08-15 00:00:00.000 | 2024-03-19 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.669 |
| 24 | 7,64        | 7,7        | 1.011,03       | 1.007,01     | 1.006,62    | 2015-05-15 00:00:00.000 | 2024-03-19 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.670 |
| 25 | 7,77        | 7,83       | 1.001,96       | 997,98       | 997,59      | 2015-05-15 00:00:00.000 | 2024-03-18 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.671 |
| 26 | 7,06        | 7,14       | 560,22         | 553,42       | 553,21      | 2024-08-15 00:00:00.000 | 2024-03-18 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.672 |
| 27 | 7,69        | 7,75       | 1.006,89       | 1.002,89     | 1.002,5     | 2015-05-15 00:00:00.000 | 2024-03-17 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.673 |
| 28 | 6,97        | 7,05       | 567,77         | 560,87       | 560,67      | 2024-08-15 00:00:00.000 | 2024-03-17 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.674 |
| 29 | 6,85        | 6,93       | 578,09         | 571,05       | 570,73      | 2024-08-15 00:00:00.000 | 2024-03-14 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.675 |
| 30 | 7,57        | 7,63       | 1.014,56       | 1.010,52     | 1.009,93    | 2015-05-15 00:00:00.000 | 2024-03-14 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.676 |
| 31 | 6,9         | 6,98       | 573,32         | 566,34       | 566,09      | 2024-08-15 00:00:00.000 | 2024-03-13 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.677 |
| 32 | 7,49        | 7,55       | 1.019,31       | 1.015,25     | 1.014,78    | 2015-05-15 00:00:00.000 | 2024-03-13 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.678 |
| 33 | 6,76        | 6,84       | 585,5          | 578,36       | 578,11      | 2024-08-15 00:00:00.000 | 2024-03-12 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.679 |
| 34 | 7,34        | 7,4        | 1.029,08       | 1.024,97     | 1.024,51    | 2015-05-15 00:00:00.000 | 2024-03-12 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.680 |
| 35 | 6,83        | 6,91       | 579            | 571,94       | 571,7       | 2024-08-15 00:00:00.000 | 2024-03-11 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.681 |
| 36 | 7,44        | 7,5        | 1.021,78       | 1.017,7      | 1.017,24    | 2015-05-15 00:00:00.000 | 2024-03-11 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.682 |
| 37 | 6,77        | 6,85       | 584,05         | 576,93       | 576,68      | 2024-08-15 00:00:00.000 | 2024-03-10 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.683 |
| 38 | 7,33        | 7,39       | 1.028,75       | 1.024,64     | 1.024,18    | 2015-05-15 00:00:00.000 | 2024-03-10 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.684 |
| 39 | 6,73        | 6,81       | 587,4          | 580,23       | 579,79      | 2024-08-15 00:00:00.000 | 2024-03-07 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.685 |
| 40 | 7,19        | 7,25       | 1.037,96       | 1.033,81     | 1.033,01    | 2015-05-15 00:00:00.000 | 2024-03-07 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.686 |
| 41 | 6,6         | 6,68       | 598,8          | 591,23       | 591,23      | 2024-08-15 00:00:00.000 | 2024-03-06 00:00:00.000 | IPCA    | 2025-11-23 09:56:35.687 |

Atualizar Salvar Cancelar Excluir Importar Exportar dados 200 200+ 200 linha(s) recuperada(s) - 0,0s (0,0s recuperado), em 2025-11-23 às 10:08:36



# S3 Bronze - PRE

Amazon S3 > Buckets > ferdellino-xpe > bronze/ > pre/ > postgres-dadosesoupre/ > partition=0/

partition=0/

Copiar URI do S3

Objetos

Propriedades

Objetos (256)

Copiar URI do S3 Copiar URL Fazer download Abrir Excluir Ações Criar pasta Carregar

Os objetos são as entidades fundamentais armazenadas no Amazon S3. Você pode usar o [inventário do Amazon S3](#) para obter uma lista de todos os objetos em seu bucket. Para outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a eles. [Saiba mais](#)

Localizar objetos por prefixo

| Nome                                    | Tipo | Última modificação          | Tamanho | Classe de armazenamento |
|-----------------------------------------|------|-----------------------------|---------|-------------------------|
| postgres-dadosesoupre+0+0000000000.json | json | 23 Nov 2025 09:14:46 AM -03 | 424.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000002.json | json | 23 Nov 2025 09:14:47 AM -03 | 424.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000004.json | json | 23 Nov 2025 09:14:49 AM -03 | 424.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000006.json | json | 23 Nov 2025 09:14:50 AM -03 | 422.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000008.json | json | 23 Nov 2025 09:14:51 AM -03 | 423.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000010.json | json | 23 Nov 2025 09:14:53 AM -03 | 424.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000012.json | json | 23 Nov 2025 09:36:09 AM -03 | 423.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000014.json | json | 23 Nov 2025 09:36:10 AM -03 | 424.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000016.json | json | 23 Nov 2025 09:36:11 AM -03 | 423.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000018.json | json | 23 Nov 2025 09:36:12 AM -03 | 424.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000020.json | json | 23 Nov 2025 09:36:14 AM -03 | 424.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000022.json | json | 23 Nov 2025 09:36:15 AM -03 | 421.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000024.json | json | 23 Nov 2025 09:36:16 AM -03 | 424.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000026.json | json | 23 Nov 2025 09:36:17 AM -03 | 423.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000028.json | json | 23 Nov 2025 09:36:18 AM -03 | 422.0 B | Padrão                  |
| postgres-dadosesoupre+0+0000000030.json | json | 23 Nov 2025 09:36:20 AM -03 | 422.0 B | Padrão                  |

## Containers Confluent/Connect/DB (docker ps)

docker desktop

Search for images, containers, volumes, extensions and more...

Containers

Container CPU usage 7.04% / 800% (8 CPUs available)

Container memory usage 3.24GB / 6.57GB

Show charts

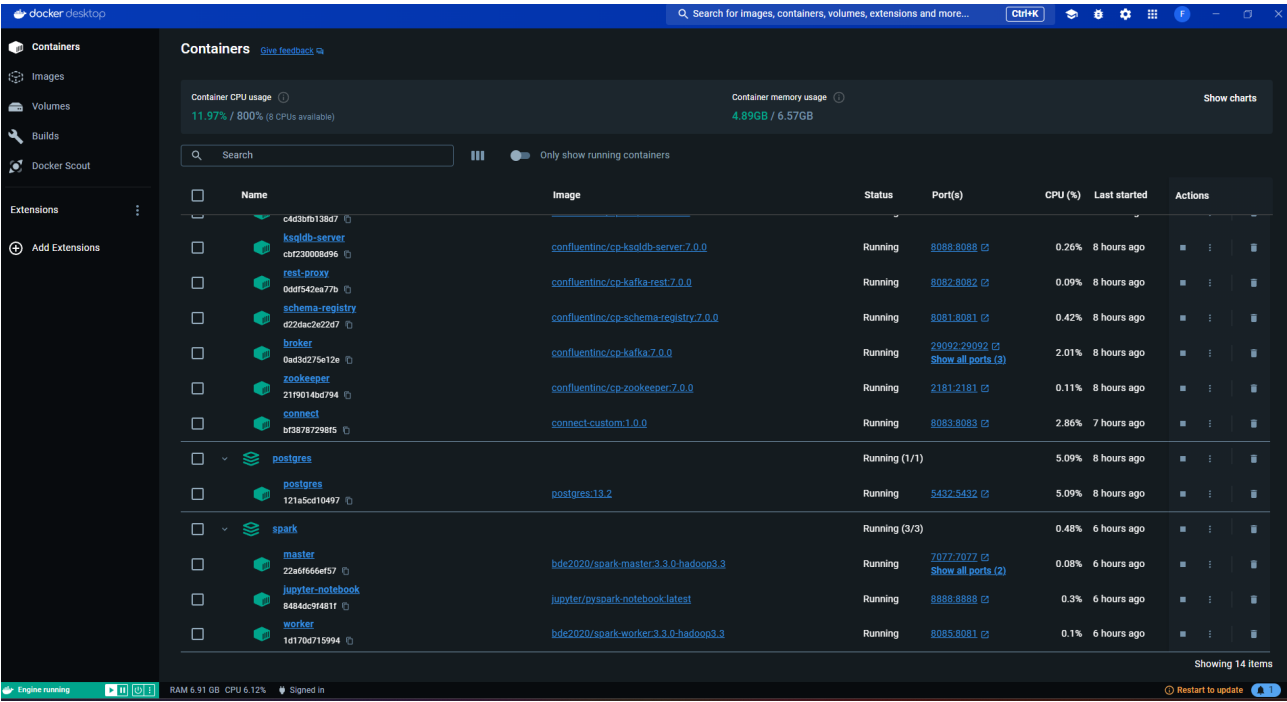
Search

Only show running containers

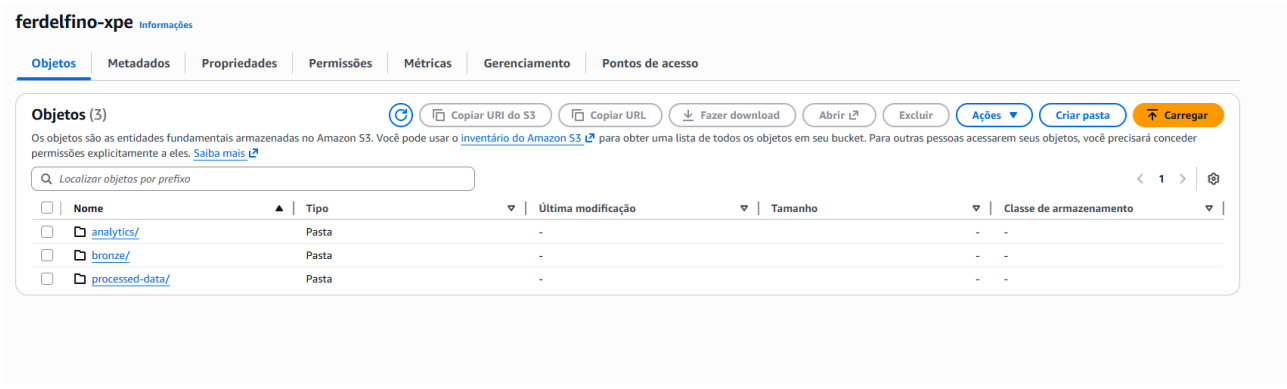
| Name            | Image                                 | Status        | Port(s)     | CPU (%) | Last started   | Actions |
|-----------------|---------------------------------------|---------------|-------------|---------|----------------|---------|
| postgres        |                                       | Running (1/1) |             | 0.3%    | 44 minutes ago |         |
| postgres        | postgres:13.2                         | Running       | 5432:5432   | 0.3%    | 44 minutes ago |         |
| proxy           |                                       | Running (7/7) |             | 6.7%    | 36 minutes ago |         |
| zookeeper       | confluentinc/cp-zookeeper:7.0.0       | Running       | 2181:2181   | 0.12%   | 36 minutes ago |         |
| broker          | confluentinc/cp-kafka:7.0.0           | Running       | 29092:29092 | 1.99%   | 36 minutes ago |         |
| connect         | connect-custom:1.0.0                  | Running       | 8083:8083   | 3.47%   | 36 minutes ago |         |
| schema-registry | confluentinc/cp-schema-registry:7.0.0 | Running       | 8081:8081   | 0.63%   | 36 minutes ago |         |
| rest-proxy      | confluentinc/cp-kafka-rest:7.0.0      | Running       | 8082:8082   | 0.1%    | 36 minutes ago |         |
| ksqldb-cli      | confluentinc/cp-ksqldb-cli:7.0.0      | Running       |             | 0%      | 36 minutes ago |         |
| ksqldb-server   | confluentinc/cp-ksqldb-server:7.0.0   | Running       | 8088:8088   | 0.39%   | 36 minutes ago |         |

Showing 10 items

# Containers Kafka/Spark/Connect (docker ps)



# Bucket AWS ferdelfino-xpe



# Spark Gold IPCA/PRE (visao)

Amazon S3 > Buckets > ferdelfino-xpe > analytics/ > ipca/ > gold/

gold/

Copiar URI do S3

Objetos

Propriedades

Objetos (2)

Copiar URI do S3 Copiar URL Fazer download Abrir Excluir Ações Criar pasta Carregar

Os objetos são as entidades fundamentais armazenadas no Amazon S3. Você pode usar o [inventário do Amazon S3](#) para obter uma lista de todos os objetos em seu bucket. Para outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a eles. [Saiba mais](#)

Localizar objetos por prefixo

|                          | Nome                                                                | Tipo    | Última modificação          | Tamanho | Classe de armazenamento |
|--------------------------|---------------------------------------------------------------------|---------|-----------------------------|---------|-------------------------|
| <input type="checkbox"/> | _SUCCESS                                                            | -       | 23 Nov 2025 09:24:45 AM -03 | 0 B     | Padrão                  |
| <input type="checkbox"/> | part-00000-4d21a762-7972-4a90-a0eb-1e78e9fa221e-c000.snappy.parquet | parquet | 23 Nov 2025 09:24:42 AM -03 | 1.3 KB  | Padrão                  |

# Spark Silver IPCA/PRE (visao)

Amazon S3 > Buckets > ferdelfino-xpe > processed-data/ > pre/ > silver/

silver/

Copiar URI do S3

Objetos

Propriedades

Objetos (2)

Copiar URI do S3 Copiar URL Fazer download Abrir Excluir Ações Criar pasta Carregar

Os objetos são as entidades fundamentais armazenadas no Amazon S3. Você pode usar o [inventário do Amazon S3](#) para obter uma lista de todos os objetos em seu bucket. Para outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a eles. [Saiba mais](#)

Localizar objetos por prefixo

|                          | Nome                                                               | Tipo    | Última modificação          | Tamanho | Classe de armazenamento |
|--------------------------|--------------------------------------------------------------------|---------|-----------------------------|---------|-------------------------|
| <input type="checkbox"/> | _SUCCESS                                                           | -       | 23 Nov 2025 09:24:09 AM -03 | 0 B     | Padrão                  |
| <input type="checkbox"/> | part-00000-3f45fda8-77c4-41a9-b300-b4870ea6b68-c000.snappy.parquet | parquet | 23 Nov 2025 09:24:06 AM -03 | 14.4 KB | Padrão                  |

# Jupyter Notebook executado (Spark)

Launcher

etl-spark.ipynb

Code

```
[21]: import os
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, from_unixtime, avg, count
from dotenv import load_dotenv

load_dotenv() # carrega AWS_* do ambiente

spark = (
 SparkSession.builder
 .appName("S3 Access Example")
 .master("local[*]")
 .config("spark.jars", "/opt/spark/jars/hadoop-aws-3.3.4.jar,/opt/spark/jars/aws-java-sdk-bundle-1.12.262.jar")
 .config("spark.hadoop.fs.s3a.impl", "org.apache.hadoop.fs.s3a.S3AFileSystem")
 .config("spark.hadoop.fs.s3a.aws.credentials.provider", "com.amazonaws.auth.EnvironmentVariableCredentialsProvider")
 .config("spark.hadoop.fs.s3a.path.style.access", "true")
 .config("spark.hadoop.fs.s3a.connection.ssl.enabled", "true")
 .getOrCreate()
)

aws_access_key = os.getenv("AWS_ACCESS_KEY_ID")
aws_secret_key = os.getenv("AWS_SECRET_ACCESS_KEY")
aws_region = os.getenv("AWS_REGION", "us-east-2")

spark._jsc.hadoopConfiguration().set("fs.s3a.access.key", aws_access_key)
spark._jsc.hadoopConfiguration().set("fs.s3a.secret.key", aws_secret_key)
spark._jsc.hadoopConfiguration().set("fs.s3a.endpoint", f"s3.{aws_region}.amazonaws.com")

print("Spark session ready")

Spark session ready

[22]: bronze_ipca = "s3a://ferdelfino-xpe/bronze/ipca/"
bronze_pre = "s3a://ferdelfino-xpe/bronze/pre/"

silver_ipca = "s3a://ferdelfino-xpe/processed-data/ipca/silver/"
silver_pre = "s3a://ferdelfino-xpe/processed-data/pre/silver/"

gold_ipca = "s3a://ferdelfino-xpe/analytics/ipca/gold/"
gold_pre = "s3a://ferdelfino-xpe/analytics/pre/gold/"

for p in [bronze_ipca, bronze_pre, silver_ipca, silver_pre, gold_ipca, gold_pre]:
 print(p)

s3a://ferdelfino-xpe/bronze/ipca/
s3a://ferdelfino-xpe/bronze/pre/
s3a://ferdelfino-xpe/processed-data/ipca/silver/
```

# Jupyter Notebook - contagens/paths

File Edit View Run Kernel Tabs Settings Help

Filter files by name

work /

| Name            | Last Modified  |
|-----------------|----------------|
| ~.py            | 5 hours ago    |
| etl-spark.ip... | 40 seconds ago |
| etl-spark.ip... | 6 hours ago    |

Launcher

etl-spark.ipynb

Code

spark session ready

```
[22]: bronze_ipca = "s3a://ferdelfino-xpe/bronze/ipca/"
 bronze_pre = "s3a://ferdelfino-xpe/bronze/pre/"

 silver_ipca = "s3a://ferdelfino-xpe/processed-data/ipca/silver/"
 silver_pre = "s3a://ferdelfino-xpe/processed-data/pre/silver/"

 gold_ipca = "s3a://ferdelfino-xpe/analytics/ipca/gold/"
 gold_pre = "s3a://ferdelfino-xpe/analytics/pre/gold/"

 for p in [bronze_ipca, bronze_pre, silver_ipca, silver_pre, gold_ipca, gold_pre]:
 print(p)

 s3a://ferdelfino-xpe/bronze/ipca/
 s3a://ferdelfino-xpe/bronze/pre/
 s3a://ferdelfino-xpe/processed-data/ipca/silver/
 s3a://ferdelfino-xpe/processed-data/pre/silver/
 s3a://ferdelfino-xpe/analytics/ipca/gold/
 s3a://ferdelfino-xpe/analytics/pre/gold/

[23]: # Ler Bronze
 df_bronze_ipca = spark.read.json(bronze_ipca)
 df_bronze_pre = spark.read.json(bronze_pre)
 print("Bronze IPCA count:", df_bronze_ipca.count())
 print("Bronze PRE count:", df_bronze_pre.count())

 Bronze IPCA count: 560
 Bronze PRE count: 512

[24]: # Silver: deduplicar, converter timestamps, tratar nulos
 def to_silver(df):
 df_s = df.dropDuplicates()
 df_s = df_s.withColumn("Data_Vencimento", from_unixtime(col("Data_Vencimento")/1000, "yyyy-MM-dd")) \
 .withColumn("Data_Base", from_unixtime(col("Data_Base")/1000, "yyyy-MM-dd")) \
 .withColumn("dt_update", from_unixtime(col("dt_update")/1000, "yyyy-MM-dd HH:mm:ss"))
 df_s = df_s.fillna({"PUCompraManha": 0, "PUVendaManha": 0, "PUBaseManha": 0})
 return df_s

 silver_ipca_df = to_silver(df_bronze_ipca)
 silver_pre_df = to_silver(df_bronze_pre)

 silver_ipca_df.write.mode("overwrite").parquet(silver_ipca)
 silver_pre_df.write.mode("overwrite").parquet(silver_pre)
 print("Silver gravado")

 Silver gravado
```



# Jupyter Notebook - Silver/Gold

← → ↺ 🏠 🌐 localhost:8888/lab/workspaces/auto-J/tree/work/etl-spark.ipynb

File Edit View Run Kernel Tabs Settings Help

+ 📁 📄 📄 📄

Filter files by name 🔍

📁 / work /

| Name                           | Last Modified |
|--------------------------------|---------------|
| 📄 -.py                         | 5 hours ago   |
| 📄 etl-spark.ip... 1 minute ago |               |
| 📄 etl-spark.ip...              | 6 hours ago   |

etl-spark.ipynb

```
silver_ipca_df.write.mode("overwrite").parquet(silver_ipca)
silver_pre_df.write.mode("overwrite").parquet(silver_pre)
print("Silver gravado")

Silver gravado

[25]: # Gold: agregações (médias e contagem por tipo)
gold_ipca_df = silver_ipca_df.groupBy("Tipo").agg(
 avg("PUCompraManha").alias("Media_PUCompraManha"),
 avg("PUVendaManha").alias("Media_PUVendaManha"),
 count("*").alias("Total_Registros")
)

gold_pre_df = silver_pre_df.groupBy("Tipo").agg(
 avg("PUCompraManha").alias("Media_PUCompraManha"),
 avg("PUVendaManha").alias("Media_PUVendaManha"),
 count("*").alias("Total_Registros")
)

gold_ipca_df.write.mode("overwrite").parquet(gold_ipca)
gold_pre_df.write.mode("overwrite").parquet(gold_pre)
print("Gold gravado")

Gold gravado

[]: spark.stop()

[]:

[]:
```

## S3/Silver IPCA (processed-data)

Amazon S3 > Buckets > ferdelfino-xpe > processed-data/ > ipca/ > silver/

silver/

Copiar URI do S3

Objetos

Propriedades

Objetos (2)

Copiar URI do S3 Copiar URL Fazer download Abrir Excluir Ações Criar pasta Carregar

Os objetos são as entidades fundamentais armazenadas no Amazon S3. Você pode usar o [inventário do Amazon S3](#) para obter uma lista de todos os objetos em seu bucket. Para outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a eles. [Saiba mais](#)

Localizar objetos por prefixo

| <input type="checkbox"/> | Nome                                                                               | Tipo    | Última modificação          | Tamanho | Classe de armazenamento |
|--------------------------|------------------------------------------------------------------------------------|---------|-----------------------------|---------|-------------------------|
| <input type="checkbox"/> | <a href="#">_SUCCESS</a>                                                           | -       | 23 Nov 2025 09:23:41 AM -03 | 0 B     | Padrão                  |
| <input type="checkbox"/> | <a href="#">part-00000-67e5d22d-1f63-467e-8505-17c3afb8e36-c000.snappy.parquet</a> | parquet | 23 Nov 2025 09:23:37 AM -03 | 15.9 KB | Padrão                  |

# S3/Silver PRE (processed-data)

Amazon S3 > Buckets > ferdeffino-xpe > processed-data/ > pre/ > silver/

silver/

Copiar URI do S3

Objetos

Propriedades

Objetos (2)

Copiar URI do S3

Copiar URL

Fazer download

Abrir

Excluir

Ações

Criar pasta

Carregar

Os objetos são as entidades fundamentais armazenadas no Amazon S3. Você pode usar o [inventário do Amazon S3](#) para obter uma lista de todos os objetos em seu bucket. Para outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a eles. [Saiba mais](#)

Localizar objetos por prefixo

< 1 >

|                          | Nome                                                                                | Tipo    | Última modificação          | Tamanho | Classe de armazenamento |
|--------------------------|-------------------------------------------------------------------------------------|---------|-----------------------------|---------|-------------------------|
| <input type="checkbox"/> | <a href="#">_SUCCESS</a>                                                            | -       | 23 Nov 2025 09:24:09 AM -03 | 0 B     | Padrão                  |
| <input type="checkbox"/> | <a href="#">part-00000-3f45fda8-77c4-41a9-b300-b4870ead6b68-c000.snappy.parquet</a> | parquet | 23 Nov 2025 09:24:06 AM -03 | 14.4 KB | Padrão                  |